



TP : Latent Semantic Analysis (LSA)

Filière IA & Data Science

Emsi Rabat, 2025/2026

Objectif du TP

Ce TP a pour objectif de :

- Représenter un corpus textuel avec TF-IDF
- Comprendre la problématique de la haute dimension
- Appliquer la méthode LSA (SVD)
- Réduire la dimension des données
- Analyser la similarité entre documents

Contexte

Dans les applications réelles, les données textuelles sont souvent représentées dans des espaces de très grande dimension .

La méthode **Latent Semantic Analysis (LSA)** permet de réduire cette dimension tout en capturant les relations sémantiques entre documents.

Introduction théorique

L'Analyse Sémantique Latente (LSA) est une technique de traitement du langage naturel qui vise à découvrir la structure sémantique sous-jacente d'un corpus. Elle repose sur l'hypothèse que les mots qui sont proches dans leur contexte ont des significations similaires.

Mathématiquement, après avoir construit la matrice terme-document X de taille $n \times d$ (où d est le nombre de documents et n la taille du vocabulaire), LSA applique la décomposition en valeurs singulières (SVD) :

$$X = U\Sigma V^T$$

où U et V sont des matrices orthogonales représentant respectivement les documents et les termes dans l'espace latent, et Σ est une matrice diagonale contenant les valeurs singulières. En tronquant cette décomposition à k dimensions ($k \ll n$), on obtient une représentation réduite $X_k = U_k \Sigma_k V_k^T$ qui capture la structure sémantique principale tout en réduisant le bruit et la dimensionnalité.

Corpus : 20 Newsgroups

Le jeu de données *20 Newsgroups* contient environ 20 000 documents répartis dans 20 catégories thématiques différentes (sports, politique, religion, etc.). Pour ce TP, nous utiliserons une version allégée pour garantir des temps de calcul raisonnables, tout en conservant la complexité sémantique du corpus.

1. Chargement et prétraitement des données

Écrivez un script Python qui charge le corpus *20 Newsgroups* depuis `scikit-learn`. Nous utiliserons un sous-ensemble de 4 catégories distinctes pour visualiser clairement la séparation sémantique.

Questions

- Quel est le nombre total de documents chargés ? Quelle est la distribution des catégories ?
- Proposez une fonction de prétraitement qui applique : mise en minuscules, suppression de la ponctuation, suppression des mots vides (stop words) et lemmatisation.
Indice : utilisez `nltk` ou `spacy`.

2. Représentation TF-IDF

Instructions

À l'aide de `TfidfVectorizer` de `scikit-learn`, transformez le corpus prétraité en une matrice terme-document.

Questions

- Quelle est la dimension de la matrice TF-IDF obtenue ? Commentez la problématique de la haute dimension.
- Calculez et visualisez la densité de la matrice (pourcentage de valeurs non nulles). Qu'en déduisez-vous sur la parcimonie des données textuelles ?
- Affichez les 10 termes ayant le plus grand score TF-IDF moyen. Interprétez ces termes.

3. LSA

Instructions

Appliquez la décomposition en valeurs singulières (SVD) tronquée sur la matrice TF-IDF. Nous utiliserons `TruncatedSVD` qui est une implémentation efficace pour les matrices creuses.

Questions

- Pour différentes valeurs de k , observez la variance expliquée cumulée. Quelle valeur de k permet de conserver 90% de la variance ?
- Interprétez les termes associés aux 5 premières composantes latentes. Quel thème sémantique chacune semble-t-elle capturer ?
- Comparez la complexité spatiale et temporelle entre l'espace TF-IDF original et l'espace latent réduit.

4. Variance expliquée et projection dans l'espace latent

Instructions

Analysez la variance expliquée par les différentes composantes.

Questions

- Interprétez le graphique de la variance expliquée cumulée. Combien de composantes sont nécessaires pour atteindre 70% de variance ? 90% ?
- Les documents de différentes catégories sont-ils bien séparés dans l'espace latent ?
- Calculez la similarité cosinus entre quelques documents de différentes catégories dans :
 - L'espace TF-IDF original
 - L'espace latent ($k=100$)Commentez les différences observées.

5. Analyse de la similarité entre documents

Instructions

Comparez la similarité entre documents dans l'espace TF-IDF original et dans l'espace latent réduit. Utilisez la similarité cosinus pour quantifier la proximité sémantique et analysez l'impact de la réduction de dimension sur la pertinence des résultats.

Questions

1. Comparez les résultats de similarité obtenus dans l'espace TF-IDF original et dans l'espace latent. Quelles différences observez-vous en termes de pertinence sémantique ?
2. Analysez les matrices de similarité visualisées. Comment la structure de la matrice change-t-elle après réduction de dimension ?
3. Interprétez les ratios intra/inter-classe calculés. Que nous apprennent-ils sur la qualité de la représentation latente ?
4. Pour un document donné, identifiez un cas où la similarité dans l'espace latent est plus pertinente que dans l'espace TF-IDF, et un cas où elle l'est moins. Expliquez pourquoi.

5. Proposez une méthode pour évaluer objectivement la qualité de la réduction de dimension en utilisant la similarité entre documents. Implémentez-la et commentez les résultats.

Bon travail et n'hésitez pas à explorer au-delà des instructions de base ! L'objectif est de développer une compréhension approfondie des techniques de réduction de dimensionnalité pour les données textuelles.